

Lezione 16 30/11/2023

Esercizio BYG (che può capitare più corto in esame)

$$\Sigma=\{a,b,c,d\}$$

T

b	a	b	c	a	b	a	a	d	c
---	---	---	---	---	---	---	---	---	---

P

a	b	c	a	b	a
---	---	---	---	---	---

B_a	100101
B_b	010010
B_c	001000
B_d	000000

$$\Sigma=\{a,b,c,d\}$$

T

b	a	b	c	a	b	a	a	d	c
---	---	---	---	---	---	---	---	---	---

P

a	b	c	a	b	a
---	---	---	---	---	---

i=1

RSHIFT1(D_0)	100000
B_b	010010

AND

D_1	000000
-------	--------

B_a	100101
B_b	010010
B_c	001000
B_d	000000

D_0 per definizione è tutti zeri.

Faccio partire la scansione, leggo il primo simbolo del testo. In questa posizione $i=1$ calcolo la parola: prendiamo la parola precedente, facciamo l'RSHIFT e la metto in AND logico alla riga di B relativa al simbolo letto.

T

b	a	b	c	a	b	a	a	d	c
---	---	---	---	---	---	---	---	---	---

P

a	b	c	a	b	a
---	---	---	---	---	---

i=2

RSHIFT1(D_1)	100000
B_a	100101

AND

D_2	100000
-------	--------

B_a	100101
B_b	010010
B_c	001000
B_d	000000

Leggo il secondo simbolo del testo, faccio un RSHIFT1 di D_1 e la metto in AND logico a B_a perchè ho letto il simbolo a.

T

b	a	b	c	a	b	a	a	d	c
---	---	---	---	---	---	---	---	---	---

P

a	b	c	a	b	a
---	---	---	---	---	---

i=3

RSHIFT1(D_2)	110000
B_b	010010
D_3	010000

AND

B_a	100101
B_b	010010
B_c	001000
B_d	000000

T

b	a	b	c	a	b	a	a	d	c
---	---	---	---	---	---	---	---	---	---

P

a	b	c	a	b	a
---	---	---	---	---	---

i=4

RSHIFT1(D_3)	101000
B_c	001000
D_4	001000

AND

B_a	100101
B_b	010010
B_c	001000
B_d	000000

T

b	a	b	c	a	b	a	a	d	c
---	---	---	---	---	---	---	---	---	---

P


a	b	c	a	b	a
---	---	---	---	---	---

i=5


RSHIFT1(D_4)	100100
B_a	100101
D_5	100100

AND

B_a	100101
B_b	010010
B_c	001000
B_d	000000




Per vedere dove inizia l'occorrenza esatta prendo la posizione 7, tolgo la lunghezza del pattern e aggiungo 1.



Esercizi KMP


Esercizio 1

A un certo punto dell'esecuzione dell'algoritmo KMP su P=acacaacca e un testo T, la finestra W si trova in posizione 15 e il primo simbolo di P che ha *mismatch* con T si trova in posizione 6. Calcolare la successiva posizione della finestra e la posizione dei simboli su T e su P da cui riparte il confronto.




Nuova posizione di W

$$p = i + j - \phi(j-1) - 1 = 15 + 6 - \phi(5) - 1 = 17$$



Posizione su T da cui riparte il confronto

$$i + j - 1 = 15 + 6 - 1 = 20$$



Posizione su P da cui riparte il confronto


$$\phi(j-1) + 1 = \phi(5) + 1 = 4$$

Esercizio 2

Il più lungo prefisso del pattern che occorre in posizione i del testo T è $P[1,5]$. Sapendo che la finestra W , durante l'esecuzione dell'algoritmo di KMP, compie un salto da i a $i+3$, determinare la lunghezza del bordo di $P[1,5]$.

$P[1,5]$, per una finestra che sta nella posizione i , è il prefisso di match. Quindi il mismatch è sul successivo.

La nuova posizione della finestra la calcoliamo come i (finestra corrente) + j (posizione di mismatch) - f_i ... (valore funzione di fallimento) - 1.



Nuova posizione di W

$$p = i + j - \phi(j-1) - 1$$

Abbiamo j , non abbiamo f_i perchè non avendo il pattern non abbiamo la funzione di fallimento. Però abbiamo p , quindi metto $i+3$ al posto di p .

Nuova posizione di W

$$i + 3 = i + 6 - \phi(5) - 1$$

$$\Rightarrow \phi(5) = 6 - 3 - 1 = 2$$

Esercizio 3


Durante l'esecuzione dell'algoritmo di KMP la finestra W si trova in posizione 11 del testo. Dopo lo spostamento alla nuova posizione, il confronto riparte dal simbolo in posizione 16 del testo.

Individuare la lunghezza del prefisso di *match* del pattern per la posizione 11 di W .

La posizione 16 è la posizione del simbolo del testo che aveva dato mismatch con il pattern, in posizione 11. $i=11$.

$$16 = i + j - 1 \Rightarrow j = 16 - 11 + 1 = 6$$

j = posizione di *mismatch* sul pattern



$j - 1 = 5 \rightarrow$ lunghezza del più lungo prefisso di P che occorre in i

$j - 1 = 5$ è la lunghezza del prefisso di match del pattern.

Gli esercizi in esame saranno simili, nei dati ci sarà tutto quello che bisogna inserire nelle formule.

Non chiede esecuzioni di KMP o pseudocodice all'esame.

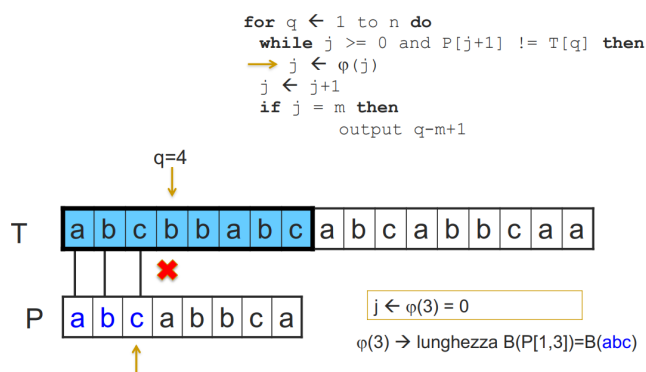
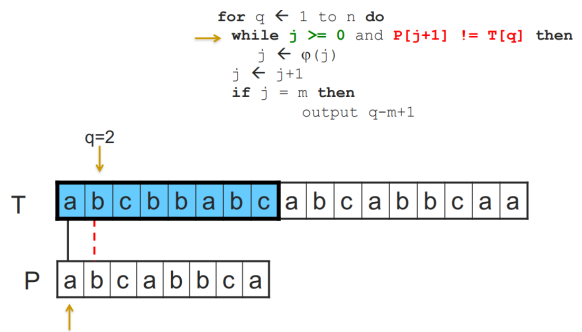
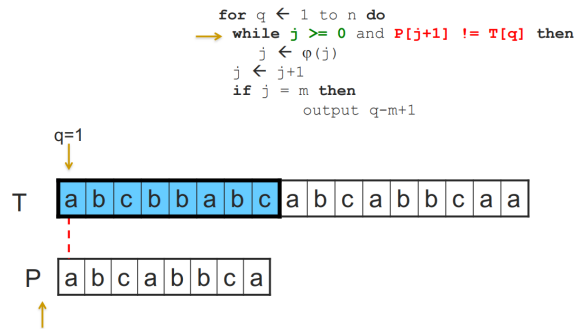
Scansione del testo T con KMP (algoritmo)

```

KMP ( $P, T, \phi$ )
begin
   $m \leftarrow |P|$ 
   $n \leftarrow |T|$ 
   $j \leftarrow 0$ 
  for  $q \leftarrow 1$  to  $n$  do
    while  $j \geq 0$  and  $P[j+1] \neq T[q]$  then
       $j \leftarrow \phi(j)$ 
     $j \leftarrow j + 1$ 
    if  $j = m$  then
      output  $q-m+1$ 
end

```

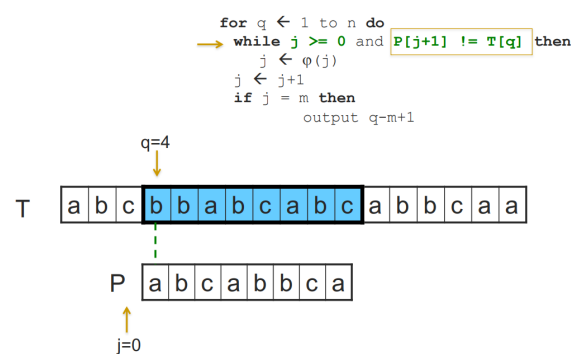
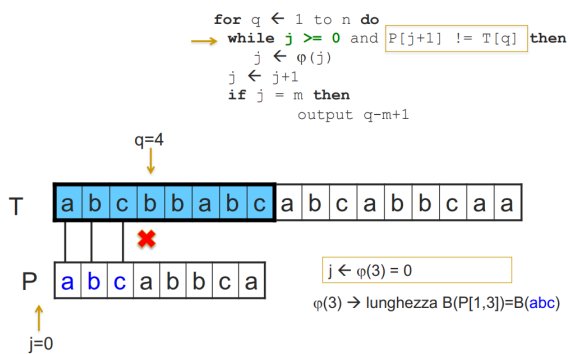
Condizioni while false




Aggiorna il valore di j tramite la funzione di fallimento phi(3).

phi è la lunghezza del bordo del pattern da 1 a 3.

Torniamo a testare la condizione del while.



La condizione è vera quindi c'è un nuovo mismatch. Aggiorna quindi j al default -1



Mi sono perso, slides sul drive (KMP-2).

Esercizi su BYG

Esercizio 1

Una word D_i dell'algoritmo BYG è uguale a 11111 e si riferisce al simbolo $T[i]=c$ sul testo. Si chiede di specificare il pattern P .

$$D_i = \underline{1}1111$$

$$D_i[1] = 1 \Rightarrow P[1,1] = \text{suff}(T[1,i]) \Rightarrow P[1] = T[i] = c$$

Il primo 1 ci dice che il prefisso lungo 1 del pattern occorre esattamente come suffisso del prefisso i del testo.

$$D_i[2] = 1 \Rightarrow P[1,2] = \text{suff}(T[1,i]) \Rightarrow P[2] = T[i] = c$$

Il prefisso lungo 2 del pattern occorre esattamente come suffisso del prefisso i del testo. Quindi il secondo simbolo del pattern è $T[i]$.

etc etc

Esercizio 2

Una word D_i dell'algoritmo di BYG è uguale a 01001. Si chiede di specificare la lunghezza del bordo del pattern.

Esaminiamo i bit a 1.

$D_i = 0100\mathbf{1}$

Questo ci dice che il prefisso lungo 5 del pattern (tutto il pattern) occorre come suffisso del prefisso i del testo.

$D_i[5] = 1 \Rightarrow P[1,5] = P = \text{suff}(T[1,i])$

$D_i[2] = 1 \Rightarrow P[1,2] = \text{suff}(T[1,i]) \Rightarrow P[1,2] = \text{suff}(P)$

Mettendo insieme le due cose posso concludere che il prefisso da 1 a 2 è suffisso di P . (Il bordo è il più lungo prefisso che occorre come suffisso)


Per capire che è il più lungo vedo gli zeri:

$D_i[3] = 0 \Rightarrow P[1,3] \neq \text{suff}(T[1,i]) \Rightarrow P[1,3] \neq \text{suff}(P)$

$D_i[4] = 0 \Rightarrow P[1,4] \neq \text{suff}(T[1,i]) \Rightarrow P[1,4] \neq \text{suff}(P)$

$\Rightarrow P[1,2] = B(P) \Rightarrow |B(P)| = 2$

In generale, data una *word* D_i , la lunghezza del bordo di P è j se e solo se $D_i[m]=1$ e j è la più grande posizione $< m$ tale che $D_i[j]=1$.

$D_i = 0110001100\mathbf{1}0000\mathbf{1}$

 $j = 11$ $|B(P)| = 11$

Esercizio 3

Sia $D_7 = 0000$ una word dell'algoritmo di BYG per $P=\text{catg}$ e un dato testo T . Sapendo che $T[5,7]=\text{atg}$, si può dire con certezza che in posizione 4 di T non c'è il simbolo c ?

$$D_7 = 0000, \quad T[5,7] = \text{atg}, \quad P = \text{catg}$$

La sottostringa di T di lunghezza 4, che finisce in posizione $i=7$, non ha *match* esatto con P

$$\Rightarrow T[4] \neq c$$

In caso contrario, si avrebbe:

$$T[4,7] = T[4] T[5,7] = \text{catg} = P$$

$$\Rightarrow D_7[4] = 1 \text{ contro l'ipotesi}$$

Sia $D_7 = 0000$ una *word* dell'algoritmo di BYG per $P=\text{catg}$ e un dato testo T. ~~Sapendo che $T[5,7] = \text{atg}$~~ , si può dire con certezza che in posizione 4 di T non c'è il simbolo c?

Non si può dire con certezza che $T[4]$ è diverso da c.

							$i=7$						
T	a	b	c	<u>c</u>	c	b	a	a	b	a	a	d	c
P	c	a	t	g									

$m=4$
 $D_7 = 0000$

Esercizio 4

Alla i -esima iterazione dell'algoritmo di BYG per cercare $P = \text{aabaa}$ (di cui si conosce la tabella B), viene calcolata la *word* $D_i = 11000$. Sapendo che la *word* D_{i-1} è uguale a D_i , specificare il simbolo di T in posizione i .

$$D_i = D_{i-1} = 11000$$

Si deve trovare la *word* B_σ tale per cui:

$$D_i = \text{RSHIFT1}(D_{i-1}) \text{ AND } B_\sigma$$

Si avrà $T[i] = \sigma$

$B_a = 11011$ $B_b = 00100$

Prova le due B della tabella una alla volta e vedi quali verifica l'equazione.

$$D_i = D_{i-1} = 11000$$

Si deve trovare la *word* B_σ tale per cui:

$$11000 = 11100 \text{ AND } \mathbf{11011}$$

Si avrà $T[i] = \mathbf{a}$

$B_a = \mathbf{11011}$ $B_b = 00100$
