

# Lezione 18 13/12/2023

## Suffix Array e Burrows-Wheeler Transform

è una struttura di indicizzazione di un testo di lunghezza  $n$ . Non contiene l'informazione sui simboli del testo, ma è un vettore di interi.

Non sta in piedi da sola, ha sempre bisogno del testo accanto.

memoria occupata  $\rightarrow \theta(n \log n)$

ricerca esatta di un pattern  $P$  lungo  $m$  in tempo  $O(m \log n)$

BWT sempre per lunghezza  $n$ , è un vettore di  $n$  elementi, ma ogni cella contiene un simbolo. Il vettore dà la permutazione (reversibile) dei simboli del testo.

memoria occupata  $\rightarrow \theta(n \log |\Sigma|)$   
usata in bzip2

FM-Index di un testo  $T$  (più recente) è una rappresentazione numerica della BWT tramite due funzioni numeriche.

ricerca esatta di un pattern lungo  $m$  in tempo  $\theta(m)$

## Ordinamento lessicografico

- ✓ I simboli di  $\Sigma$  sono ordinati lessicograficamente
- ✓  $\Sigma$  viene esteso il simbolo  $\$$  considerato lessicograficamente minore di tutti gli altri
- ✓ Il simbolo  $\$$  è usato come terminatore del testo
- ✓  $n$  è la lunghezza del testo  $\$$ -terminato

$T$ 

1	2	3	4	5	6	7	8	9
g	g	t	c	a	g	t	c	\$

 $\Sigma = \{\$, a, c, g, t\}$   $\$ < a < c < g < t$

Viene dato un ordinamento all'alfabeto, e viene aggiunto il simbolo terminatore ( $\$$ ). Tutti i testi saranno terminati dal  $\$$ . Questo è il simbolo più piccolo dell'alfabeto, inferiore agli altri. La lunghezza del testo quindi comprende anche il testo, che nell'esempio è lungo 9, non 8.

## Suffisso di indice $q$

è il suffisso che inizia nella posizione  $q$  del testo e finisce in posizione  $n$  (ultima).

DEF: il suffisso di indice  $q$  ( $q$ -suffisso) è il suffisso che inizia nella posizione  $q$  del testo, cioè  $T[q, n]$

1 2 3 4 5 6 7 8 9  
T g g t c a g t c \$  
 $\Sigma = \{\$, a, c, g, t\}$   $\$ < a < c < g < t$

**ES1:** suffisso di indice 3  $\rightarrow T[3,9] = \text{tcagtc\$}$

1 2 3 4 5 6 7 8 9  
T g g t c a g t c \$  
 $\Sigma = \{\$, a, c, g, t\}$   $\$ < a < c < g < t$

**ES2:** suffisso di indice 9  $\rightarrow T[9,9] = \$$  (suffisso nullo)

l'n-suffisso è quindi il suffisso nullo,  
perché contiene solo il dollaro.

1 2 3 4 5 6 7 8 9  
T g g t c a g t c \$  
 $\Sigma = \{\$, a, c, g, t\}$   $\$ < a < c < g < t$

**ES3:** suffisso di indice 1  $\rightarrow T[1,9] = \text{ggtcagtc\$}$  (testo T)

l'1-suffisso è invece quello che include  
tutto il testo.

## Ordinamento dei suffissi

Dati due suffissi  $s$  e  $s'$ , sia  $i$  la più piccola posizione tale  
che  $s[i] \neq s'[i]$ .

$s[i] < s'[i] \Rightarrow s < s'$  (oppure  $s' > s$ )  
 $s[i] > s'[i] \Rightarrow s > s'$  (oppure  $s' < s$ )

Quindi il suffisso in comune è quello  $i-1$ .

Per ordinare i suffissi  
andiamo quindi a vedere  
l'ordinamento del simbolo  
nella posizione  $i$ .

1 2 3 4 5 6 7 8 9  
T g g t c a g t c \$  
 $\Sigma = \{\$, a, c, g, t\}$   $\$ < a < c < g < t$

1 2 3 4 5 6 7 8 9  
T g g t c a g t c \$  
 $\Sigma = \{\$, a, c, g, t\}$   $\$ < a < c < g < t$

6-suffisso  $\rightarrow s = \text{gtc\$}$

1-suffisso  $\rightarrow s' = \text{ggtcagtc\$}$

$i = 2, s[i] > s'[i] \Rightarrow s > s'$  (oppure  $s' < s$ )

Quindi la prima posizione  
diversa è la posizione 2

La prima posizione diversa è la 4. Dico quindi che  $s < s'$ .

1	2	3	4	5	6	7	8	9
T	g	g	t	c	a	g	t	c
								\$

$\Sigma = \{\$, a, c, g, t\}$      $\$ < a < c < g < t$

La posizione  $i$  non può andare oltre la posizione del dollaro.

6-suffisso  $\rightarrow s = \text{gtc}\$$

2-suffisso  $\rightarrow s' = \text{gtcagtc}\$$

$i = 4, s[i] < s'[i] \Rightarrow s < s'$  (oppure  $s' > s$ )

## Suffix Array (SA)

DEF: il Suffix Array (SA) di un testo  $T$  lungo  $n$  è un array  $S$  lungo  $n$ , tale che  $S[i] = q$  se e solo se il  $q$ -suffisso è l' $i$ -esimo suffisso nell'ordinamento lessicografico dei suffissi di  $T$ .

Posizione  $i_1 \rightarrow S[i_1]$ -suffisso

Posizione  $i_2 \rightarrow S[i_2]$ -suffisso

$i_1 < i_2 \Rightarrow S[i_1]\text{-suffisso} < S[i_2]\text{-suffisso}$

Queste sono le loro posizioni di inizio nel testo. Se prendiamo due posizione ( $i_1 < i_2$ ) sul suffix array, sappiamo subito che  $S[i_1]$ -suffisso è minore del  $S[i_2]$ -suffisso.

1	2	3	4	5	6	7	8	9
T	g	g	t	c	a	g	t	c
								\$

$\$ < a < c < g < t$

Suffix Array?

Elenco dei suffissi per indice crescente

1	g g t c a g t c \$
2	g t c a g t c \$
3	t c a g t c \$
4	c a g t c \$
5	a g t c \$
6	g t c \$
7	t c \$
8	c \$
9	\$

Ordinamento dei suffissi

9	\$
5	a g t c \$
8	c \$
4	c a g t c \$
1	g g t c a g t c \$
6	g t c \$
2	g t c a g t c \$
7	t c \$
3	t c a g t c \$

L'ordinamento è dato dalle posizioni delle lettere dell'alfabeto. (questo non è l'algoritmo di costruzione del suffix array)

Questa colonna è quindi il suffix array. è un vettore lungo come il testo, indicizzato dall'alto, e contiene una permutazione delle posizioni del testo. Abbiamo quindi perso le informazioni sui singoli, abbiamo solo un vettore di posizioni.

$\theta(n \log n)$  in spazio

**ESEMPIO:** il settimo suffisso nell'ordinamento lessicografico è quello che inizia in posizione 2 del testo

Suffix Array S

1	9
2	5
3	8
4	4
5	1
6	6
7	2
8	7
9	3

## Ricerca esatta con SA

1. Preprocessing del testo T per costruire il Suffix Array
2. Ricerca in tempo  $O(m \log n)$  di un pattern P di lunghezza m

### Qualche osservazione...

① se P occorre k volte in T, allora P è prefisso di k suffissi di T

T = x**ab**xab\$

P = ab

P occorre 2 volte in T  $\Rightarrow$  P è prefisso di due suffissi di T:  
✓ 2-suffisso abxab\$

T = xabx**ab**\$

P = ab

P occorre 2 volte in T  $\Rightarrow$  P è prefisso di due suffissi di T:  
✓ 2-suffisso abxab\$  
✓ 5-suffisso ab\$

② gli indici dei k suffissi sono le occorrenze di P e sono consecutivi nel Suffix Array

T = xabx**ab**\$

P = ab

S	
7	\$
5	ab\$
2	abxab\$
6	b\$
3	bxab\$
4	xab\$
1	xabxab\$

③ se  $P$  è prefisso del  $q$ -suffisso ed è minore (maggiore) di un  $q'$ -suffisso, allora anche il  $q$ -suffisso sarà minore (maggiore) del  $q'$ -suffisso

Questa osservazione serve per muoversi sul suffix array ed isolare il segmento corretto che può contenere i suffissi che hanno  $P$  come prefisso. Esempio qui sotto:

## Algoritmo $O(m \log n)$

- 1) Si inizializza un intervallo di posizioni  $[L, R]$  uguale a  $[1, n]$
- 2) Si considera il suffisso di indice  $S[p]$  con  $p$  posizione di mezzo di  $[L, R]$ , e si verifica in tempo  $O(m)$  se:
  - (a)  $P < S[p]$ -suffisso  
si ripete **2)** ponendo  $[L, R] = [L, p-1]$
  - (b)  $P > S[p]$ -suffisso  
si ripete **2)** ponendo  $[L, R] = [p+1, R]$
  - (c)  $P$  è prefisso di  $S[p]$ -suffisso  
 $\Rightarrow P$  occorre in posizione  $S[p]$

Questo algoritmo trova un'occorrenza (la prima che trova), per trovare le altre dovrei muovermi sopra e sotto a quello trovato (non ci interessa). Esempio 1:

$T = \text{xabxab\$}$   
 $P = \text{ab}$

	S	
1	7	\$
2	5	ab\$
3	2	abxab\$
4	6	b\$
5	3	bxab\$
6	4	xab\$
7	1	xabxab\$

$p = 4, S[p] = 6$

$P < 6$ -suffisso =  $\text{b\$}$

nuovo intervallo  $\rightarrow [1, 3]$

$T = \text{xabxab\$}$   
 $P = \text{ab}$

	S	
1	7	\$
2	5	ab\$
3	2	abxab\$
4	6	b\$
5	3	bxab\$
6	4	xab\$
7	1	xabxab\$

$p = 2, S[p] = 5$

$P = \text{prefisso di } 5\text{-suffisso} = \text{ab\$}$

$\rightarrow 5$  è occorrenza esatta di  $P$  in  $T$

Esempio 2 (pattern che non occorre in  $T$ ):

T = xabxab\$  
P = aba

	S
1	7 \$
2	5 ab\$
3	2 abxab\$
4	6 b\$
5	3 bxab\$
6	4 xab\$
7	1 xabxab\$

p = 4, S[p] = 6

P < 6-suffisso = b\$

nuovo intervallo → [1,3]

T = xabxab\$  
P = aba

	S
1	7 \$
2	5 ab\$
3	2 abxab\$
4	6 b\$
5	3 bxab\$
6	4 xab\$
7	1 xabxab\$

p = 2, S[p] = 5

P > 5-suffisso = ab\$

nuovo intervallo → [3,3]

T = xabxab\$  
P = aba

[3,2]

p = 3, S[p] = 2

P < 2-suffisso = abxab\$

nuovo intervallo → [3,2]

→ P non occorre in T

	S
1	7 \$
2	5 ab\$
3	2 abxab\$
4	6 b\$
5	3 bxab\$
6	4 xab\$
7	1 xabxab\$

Noi prendiamo il suffix array come struttura di supporto al BWT.

## Burrows-Wheeler Transform (BTW)

### Esempio di BWT (Wikipedia)

TRENTATRE.TRENTINI.ANDARONO.A.TRENTO.TUTTI.E.TRENTATRE.TROTTERELLANDO



OIIEEAE...LDTTNN.RRRRRRTNTTLEAAIOEEEENTRDRTTETTTTATNNTTNNAO....OU.T

BWT → permutazione reversibile dei simboli del testo T

## Rotazione di indice q

DEF: la rotazione di indice q (q-rotazione) è la concatenazione del q-suffisso  $T[q,n]$  e del prefisso  $T[1,q-1]$

	1	2	3	4	5	6	7	8	9
T	g	g	t	c	a	g	t	c	\$

$\Sigma = \{\$, a, c, g, t\}$      $\$ < a < c < g < t$

**ES1**: rotazione di indice 3  $\rightarrow T[3,9] T[1,2] = \underline{tcagtc} \underline{gg}$

La q-rotazione inizia con il q-suffisso.

	1	2	3	4	5	6	7	8	9
T	g	g	t	c	a	g	t	c	\$

$\Sigma = \{\$, a, c, g, t\}$      $\$ < a < c < g < t$

**ES2**: rotazione di indice 9  $\rightarrow T[9,9] T[1,8] = \underline{\$gtcagtc}$

	1	2	3	4	5	6	7	8	9
T	g	g	t	c	a	g	t	c	\$

$\Sigma = \{\$, a, c, g, t\}$      $\$ < a < c < g < t$

**ES3**: rotazione di indice 1  $\rightarrow T[1,9] T[1,0] = \underline{ggtcagtc\$}$

La n-rotazione sposta il dollaro ad inizio testo.

La 1-rotazione coincide con il testo completo e con l'1-suffisso.

La q-rotazione r è una stringa lunga n che ha:

1. il q-suffisso come prefisso
2. il prefisso lungo q-1 come suffisso

$\Rightarrow r[1]$  è uguale a  $T[q]$  (primo simbolo del q-suffisso)

$\Rightarrow r[n]$  è uguale a  $T[q-1]$  se  $q > 1$

$\Rightarrow r[n]$  è uguale a  $T[n]$  se  $q = 1$

$\Rightarrow$  l'ultimo simbolo della q-rotazione è il simbolo che in T precede il q-suffisso (se  $q > 1$ ) oppure è il simbolo  $T[n]$  (se  $q = 1$ )

Il primo simbolo della rotazione è sempre uguale al simbolo q nel testo.

L'ultimo simbolo della rotazione è uguale al simbolo in posizione q-1 se  $q > 1$ , altrimenti se  $q = 1$  è l'ultimo simbolo del testo.

Esempi:

	1	2	3	4	5	6	7	8	9
T	g	g	t	c	a	g	t	c	\$

$\Sigma = \{\$, a, c, g, t\}$      $\$ < a < c < g < t$

3-rotazione  $r = \underline{tcagtc} \underline{gg}$

	1	2	3	4	5	6	7	8	9
T	g	g	t	c	a	g	t	c	\$

$\Sigma = \{\$, a, c, g, t\}$      $\$ < a < c < g < t$

1-rotazione  $r = \underline{ggtcagtc\$}$

$\Rightarrow r[1]$  è uguale a  $T[q]$  (primo simbolo del q-suffisso)  
 $\Rightarrow r[n]$  è uguale a  $T[q-1]$  se  $q > 1$   
 $\Rightarrow r[n]$  è uguale a  $T[n]$  se  $q = 1$

$\Rightarrow$  l'ultimo simbolo della q-rotazione è il simbolo iniziale della (q-1)-rotazione (e quindi del (q-1)-suffisso) se  $q > 1$   
 $\Rightarrow$  il (q-1)-suffisso contiene il q-suffisso come suffisso se  $q > 1$

	1	2	3	4	5	6	7	8	9
T	g	g	t	c	a	g	t	c	\$

$\Sigma = \{\$, a, c, g, t\} \quad \$ < a < c < g < t$

3-rotazione  $r = \underline{tcagtc}g\bar{g}$

3-rotazione  $r = \underline{tcagtc}g\bar{g}$

2-rotazione  $r' = \underline{gtcagtc}g\bar{g}$

Quindi se prendo l'ultimo simbolo della 3-rotazione e lo sposto alla prima posizione, ottengo la 2-rotazione.

$\Rightarrow r[n]$  è uguale a  $T[n]$  se  $q = 1$

$\Rightarrow$  l'ultimo simbolo della q-rotazione è il simbolo iniziale della n-rotazione (e quindi dell'n-suffisso) se  $q = 1$

	1	2	3	4	5	6	7	8	9
T	g	g	t	c	a	g	t	c	\$

$\Sigma = \{\$, a, c, g, t\} \quad \$ < a < c < g < t$

1-rotazione  $r = \underline{ggtcagtc}\bar{g}$

	1	2	3	4	5	6	7	8	9
T	g	g	t	c	a	g	t	c	\$

$\Sigma = \{\$, a, c, g, t\} \quad \$ < a < c < g < t$

1-rotazione  $r = \underline{ggtcagtc}\bar{g}$

9-rotazione  $r' = \underline{\$ggtcagtc}$

## Ordinamento delle rotazioni

Date due rotazioni  $r$  e  $r'$ , sia  $i$  la più piccola posizione tale che  $r[i] \neq r'[i]$ .

$r[i] < r'[i] \Rightarrow r < r'$  (oppure  $r' > r$ )

$r[i] > r'[i] \Rightarrow r > r'$  (oppure  $r' < r$ )

è la stessa regola di prima

Esempi:

	1	2	3	4	5	6	7	8	9
T	g	g	t	c	a	g	t	c	\$

$\Sigma = \{\$, a, c, g, t\} \quad \$ < a < c < g < t$

6-rotazione  $\rightarrow r = \underline{gtc}\$gggtca$

1-rotazione  $\rightarrow r' = \underline{gg}gtcagtc\$$

$i = 2, \quad r[i] > r'[i] \quad \Rightarrow \quad r > r'$  (oppure  $r' < r$ )

	1	2	3	4	5	6	7	8	9
T	g	g	t	c	a	g	t	c	\$

$\Sigma = \{\$, a, c, g, t\} \quad \$ < a < c < g < t$

6-rotazione  $\rightarrow r = \underline{gtc}\$gggtca$

2-rotazione  $\rightarrow r' = \underline{gtc}agtc\$g$

$i = 4, \quad r[i] < r'[i] \quad \Rightarrow \quad r < r'$  (oppure  $r' > r$ )

In generale, la q-rotazione è minore della p-rotazione se e solo se il q-suffisso è minore del p-suffisso



Grazie all'aggiunta del simbolo finale \$, le q-rotazioni e i q-suffissi sono sincronizzati, se una q-rotazione è minore di un'altra p-rotazione allora il q-suffisso è minore del p-suffisso.

---

Date una q-rotazione  $r_1$  e una p-rotazione  $r_2$  tali che:

1.  $r_1 < r_2$
2.  $r_1[n] = r_2[n]$

Allora la (q-1)-rotazione  $r'_1$  è minore della (p-1)-rotazione  $r'_2$

	1	2	3	4	5	6	7	8	9
T	g	g	t	c	a	g	t	c	\$

 $\Sigma = \{\$, a, c, g, t\} \quad \$ < a < c < g < t$ 

7-rotazione  $r_1 = tc\$ggtcag < 3\text{-rotazione } r_2 = tcagtc\$gg$

$\Rightarrow$  6-rotazione < 2-rotazione

Questo se i due simboli finali sono uguali.

Date una q-rotazione  $r_1$  e una p-rotazione  $r_2$  tali che:

1.  $r_1 < r_2$
2.  $r_1[n] < r_2[n]$

Allora la (q-1)-rotazione  $r'_1$  è minore della (p-1)-rotazione  $r'_2$

	1	2	3	4	5	6	7	8	9
T	g	g	t	c	a	g	t	c	\$

 $\Sigma = \{\$, a, c, g, t\} \quad \$ < a < c < g < t$ 

3-rotazione  $r_2 = tcagtc\$gg$       8-rotazione  $r_2 = \underline{c\$ggtcagt}$

$\Rightarrow$  2-rotazione < 7-rotazione

## Definizione di BWT

**DEF:** la BWT B di un testo T lungo n è un array di lunghezza n tale che  $B[i] = r_i[n]$  se e solo se  $r_i$  è l'i-esima rotazione nell'ordinamento lessicografico delle rotazioni di T.

Nella posizione i-esima di BWT c'è un simbolo.

Immaginiamo di avere tutte le rotazioni del testo, di ordinarle lessicograficamente, prendiamo l'ultimo simbolo della rotazione più piccola e la metto in BWT.

Esempio:

1 2 3 4 5 6 7 8 9  
T g g t c a g t c \$

① Riempiamo una matrice n x n con tutte le rotazioni di T

1	g	g	t	c	a	g	t	c	\$
2	g	t	c	a	g	t	c	\$	g
3	t	c	a	g	t	c	\$	g	g
4	c	a	g	t	c	\$	g	g	t
5	a	g	t	c	\$	g	g	t	c
6	g	t	c	\$	g	g	t	c	a
7	t	c	\$	g	g	t	c	a	g
8	c	\$	g	g	t	c	a	g	t
9	\$	g	g	t	c	a	g	t	c

1 2 3 4 5 6 7 8 9  
T g g t c a g t c \$

② Ordiniamo lessicograficamente le rotazioni

9	\$	g	g	t	c	a	g	t	c
5	a	g	t	c	\$	g	g	t	c
8	c	\$	g	g	t	c	a	g	t
4	c	a	g	t	c	\$	g	g	t
1	g	g	t	c	a	g	t	c	\$
6	g	t	c	\$	g	g	t	c	a
2	g	t	c	a	g	t	c	\$	g
7	t	c	\$	g	g	t	c	a	g
3	t	c	a	g	t	c	\$	g	g

In ogni riga ci mettiamo una rotazione.

1 2 3 4 5 6 7 8 9  
T g g t c a g t c \$

La BWT B è l'ultima colonna della matrice delle rotazioni ordinate lessicograficamente

$\theta(n \log |\Sigma|)$  in spazio

BWT B  
c  
c  
t  
t  
\$  
a  
g  
g  
g

L'ultima colonna è la BWT. Salva quindi l'ultimo simbolo delle rotazioni, con le rotazioni in ordine lessicografico.

	F									BWT B
9	\$									c
5	a									c
8	c									t
4	c									t
1	g									\$
6	g									a
2	g									g
7	t									g
3	t									g

La prima colonna (F) contiene i simboli iniziali delle rotazioni ordinate. (Mentre la BWT sono i simboli finali delle rotazioni ordinate)

F fornisce sempre l'ordinamento lessicografico dei simboli del testo.

1 2 3 4 5 6 7 8 9  
T g g t c a g t c \$

Sia  $B[i] = r_i[n]$  con  $r_i$  i-esima più piccola rotazione nell'ordinamento lessicografico.

Se  $r_i$  è la q-rotazione di T, allora  $B[i]$  è l'ultimo simbolo della q-rotazione, cioè  $T[q-1]$ .

Il primo simbolo della q-rotazione è il simbolo  $T[q]$  e coincide con il simbolo in posizione  $F[i]$  del vettore F.

#### ESEMPIO:

per  $i=3$

- $B[i] = t$  coincide con  $T[7]$
- $F[i] = c$  coincide con  $T[8]$

	F								BWT B
9	\$								c
5	a								c
8	c								t
4	c								t
1	g								\$
6	g								a
2	g								g
7	t								g
3	t								g

## Prima proprietà

1 2 3 4 5 6 7 8 9  
T g g t c a g t c \$

Per ogni posizione i, il simbolo  $B[i]$  precede nel testo il simbolo  $F[i]$

→ Proprietà P1

#### ESEMPIO:

per  $i=6$

- $B[i] = a$  coincide con  $T[5]$
- $F[i] = g$  coincide con  $T[6]$

	F								BWT B
9	\$								c
5	a								c
8	c								t
4	c								t
1	g								\$
6	g								a
2	g								g
7	t								g
3	t								g

1 2 3 4 5 6 7 8 9  
T g g t c a g t c \$

Per ogni posizione i, il simbolo  $B[i]$  precede nel testo il simbolo  $F[i]$

→ Proprietà P1

#### ESEMPIO:

per  $i=1$

- $B[i] = c$  coincide con  $T[8]$
- $F[i] = $$  coincide con  $T[9]$

	F								BWT B
9	\$								c
5	a								c
8	c								t
4	c								t
1	g								\$
6	g								a
2	g								g
7	t								g
3	t								g

NB:  $B[1]$  è sempre  $T[n-1]$

1 2 3 4 5 6 7 8 9  
T g g t c a g t c \$

Per ogni posizione i tale che  $B[i]$  è diverso da \$, il simbolo  $B[i]$  precede nel testo il simbolo  $F[i]$ .  
Se  $B[i] = $$ , allora  $F[i] = T[1]$

→ Proprietà P1

#### ESEMPIO:

per  $i=5$

- $B[i] = $$  coincide con  $T[9]$
- $F[i] = g$  coincide con  $T[1]$

	F								BWT B
9	\$								c
5	a								c
8	c								t
4	c								t
1	g								\$
6	g								a
2	g								g
7	t								g
3	t								g

Modifichiamo leggermente la (prima) proprietà per farla funzionare anche con il dollaro.